Manual de Despliegue en la Nube

Fase II: Detección inteligente de fraude transaccional Alumno(a): [Tu Nombre/Matrícula]

1. Estrategia de Despliegue

Para asegurar que el modelo pase de un entorno de pruebas a un entorno productivo robusto y confiable, se optará por una estrategia **PaaS (Platform as a Service)** utilizando **Google Cloud Run**. Esta arquitectura Serverless permite desplegar contenedores escalables sin la necesidad de administrar servidores subyacentes, lo cual optimiza costos (solo se paga por las peticiones recibidas) y garantiza alta disponibilidad.

2. Requerimientos Técnicos

Para llevar a cabo este despliegue, el ingeniero o administrador de sistemas debe contar con:

1. Una cuenta activa de Google Cloud Platform (GCP) con facturación habilitada.
2. La herramienta de línea de comandos **Google Cloud SDK (gcloud)** instalada.
3. Docker Engine instalado localmente (o utilizar Google Cloud Shell).
4. La imagen funcional del contenedor creada previamente (`api-fraude-dual`).
5. Permisos de administrador en el proyecto de GCP (rol `Cloud Run Admin`).

3. Proceso Paso a Paso

Los siguientes comandos deben ser ejecutados en la terminal del sistema donde se encuentre configurado el entorno:

Paso 1: Autenticación en la plataforma Inicia sesión en Google Cloud y vincula la consola local con tu cuenta institucional o corporativa: `gcloud auth login`

Paso 2: Selección del proyecto activo Indica el ID del proyecto donde residirán los recursos (reemplazar `[ID_PROYECTO]` por el correspondiente): `gcloud config set project [ID_PROYECTO]`

Paso 3: Etiquetado de la imagen Docker Prepara la imagen local para ser subida al Container Registry de Google Cloud (GCR). Esto estandariza la nomenclatura: `docker tag api-fraude-dual gcr.io/[ID_PROYECTO]/api-fraude-dual:v1`

Paso 4: Subida de la imagen (Push) Sube la imagen desde el almacenamiento local hacia la nube segura de Google: `docker push gcr.io/[ID_PROYECTO]/api-fraude-dual:v1`

Paso 5: Despliegue del contenedor en Cloud Run Ejecuta el servicio administrado, asignando puerto, recursos y políticas de acceso. En este caso, al ser una API que será

consumida por un frontend interno o balanceador de carga, restringiremos el acceso temporalmente (ajustable posteriormente según la arquitectura de red): `gcloud run deploy api-fraude-dual \ --image gcr.io/[ID_PROYECTO]/api-fraude-dual:v1 \ --platform managed \ --port 8000 \ --allow-unauthenticated`

Paso 6: Validación de URL productiva Una vez finalizado, la consola arrojará una URL pública (ej. `https://api-fraude-dual-xyz.a.run.app`). Esta URL reemplazará a `localhost` o `127.0.0.1` en el entorno frontend del banco para realizar las peticiones POST de transacciones.

4. Consideraciones de Seguridad y Mantenimiento

Tomando en cuenta los riesgos establecidos en la Fase I, el despliegue considera lo siguiente:

- **Seguridad en el tránsito (R-01):** Google Cloud Run aplica por defecto certificados TLS 1.2+ en el endpoint generado.
- **Protección de IA (R-04):** Todas las entradas que provengan del cliente a este contenedor desplegado deben ser rigurosamente verificadas en cuanto a formato y tipo de dato (Input Sanitization) mediante la librería `Pydantic` de FastAPI para mitigar riesgos de *Prompt Injection* hacia el LLM integrado.